Agence Nationale de la Statistique – Côte d'Ivoire

Enquête Nationale sur l'Emploi auprès des Ménages

Pipeline d'Apurement

Volet Ménages

Documentation technique

Version 1.0 – Avril 2026

Outil : Stata 17 | Collecte : Survey Solutions | Contrôle de version : Git

Table des matières

1 Vue d'ensemble du pipeline **2**

2 Architecture des fichiers **2**
2.1 Dossiers de données 2
2.2 Fichiers de programme 2

3 Séquence d'exécution **2**

4 Méthodologie d'apurement **3**

5 Stratégie d'imputation par médiane **4**

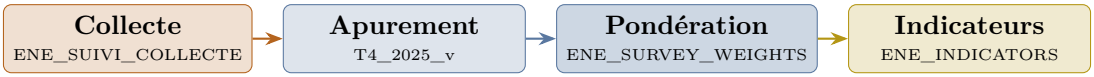
6 Gestion de la qualité **4**
6.1 Entretiens supprimés 4
6.2 Traçabilité des erreurs 4

7 Variables construites **4**

8 Points d'attention pour la prochaine vague **5**

Vue d'ensemble du pipeline

Le pipeline d'apurement de l'ENEM-Ménages T4 2025 couvre la **Phase 5 du GSBPM** (traitement statistique). Il s'insère dans une chaîne de production plus large :



L'entrée du pipeline est constituée des exports bruts Survey Solutions (`datain/brute/`). La sortie est un ensemble de bases standardisées et apurées par section (`datain/standard/`), prêtes à être fusionnées puis transmises au module de pondération.

Architecture des fichiers

Dossiers de données

Dossier	Contenu
`datain/brute/`	18 fichiers `.dta` exports Survey Solutions (ménage, membres, revenus, activités, etc.)
`datain/standard/`	Bases découpées par section après `standard_db.do`
`datatemp/`	Fichiers intermédiaires de codification des emplois
`dataout/`	Bases finales fusionnées (ménage + individus)
`document/`	Fichiers Excel d'erreurs exportés lors de l'apurement

Fichiers de programme

Fichier	Rôle
`apurement.do`	Orchestrateur principal – appelle tous les do-files dans l'ordre
`parentfile.do`	Déclaration des chemins globaux (`$datain_brute`, `$dofiles`, etc.)
`Suppression_entretiens_T4-2025.do`	Suppression des entretiens invalides (138 clés) sur tous les fichiers bruts
`01-traitrement_autres.do`	Recodage des réponses « autres à préciser »
`Codification_T4_2025.do`	Codification CIAP/CITP des emplois et construction de `branche1`, `branche2`, `code_citp3_*`
`Rename_label_var.do`	Labellisation des variables binaires issues des questions à choix multiples
`standard_db.do`	Découpage de la base brute en fichiers section par section
`01-QM_S1` à `S7`	Apurement des sections ménage
`01-INDIV_S1` à `S14`	Apurement des sections individu
`Fusion.do / Fusion_ENE.do`	Fusion des sections en base finale

Séquence d'exécution

Le fichier `apurement.do` exécute les étapes dans l'ordre suivant :

Étape 1 `Suppression_entretiens_T4-2025.do`

Suppression de **138 entretiens invalides** (vides ou en surnombre) sur l'ensemble des 18 fichiers `.dta` de `datain/brute/`. Utilise un `tempfile` de clés et une boucle `foreach` avec `merge m:1 ... keep(master)`.

Étape 2 `01-traitrement_autres.do`

Recodage des champs texte libres (« à préciser ») en catégories numériques standardisées (statut, ethnie, religion, assurance, spécialité).

Étape 3 `Codification_T4_2025.do`

- Importation des fichiers de codification Excel
- Construction de `code_citp_emp_principal` (6 positions CITP-08)
- Construction de `code_citp3_emp_principal` (3 positions, groupe de base)
- Construction de `branche1` (Agriculture / Industrie / Commerce / Autre service)
- Construction de `branche2` (Primaire / Secondaire / Tertiaire)

Étape 4 `Rename_label_var.do`

Labellisation des variables binaires issues des questions à choix multiples (0 = Non, 1 = Oui).

Étape 5 `standard_db.do`

Découpage de la base brute unifiée en fichiers section par section : `QM_S0_identification`, `QM_S7_logement`, `INDIV_S1` à `INDIV_S14`, etc.

Étapes 6–12 `01-QM_S1 à 01-QM_S7 (sections ménage)`

Apurement des 7 sections ménage.

Étapes 13–26 `01-INDIV_S1 à 01-INDIV_S14 (sections individu)`

Apurement des 14 sections individu.

Méthodologie d'apurement

Chaque variable est traitée selon une séquence standard en quatre étapes :

1. **Valeurs manquantes** : identification des individus éligibles n'ayant pas répondu ; export Excel pour retour enquêteur si nécessaire.
2. **Cohérence des sauts** : vérification que seuls les individus éligibles ont répondu ; annulation des réponses hors cible.
3. **Valeurs permises** : contrôle des plages attendues (ex. : heures travaillées ≤ 168, âge cohérent avec niveau d'éducation).
4. **Vraisemblance** : détection des incohérences inter-variables (ex. : heures effectives > heures habituelles).

Stratégie d'imputation par médiane

Pour les variables continues à valeurs manquantes résiduelles (principalement les heures de travail WKT et le loyer L6), une imputation par **médiane stratifiée** est appliquée en trois passes successives, du plus fin au plus grossier :

Passe	Variables de stratification	Déclencheur
1	`EP3 branche1 code_citp3 HH12 HH6`	Cellule non vide
2	`EP3 branche1 HH12 HH6`	Toujours manquant après passe 1
3	`EP3 branche1`	Toujours manquant après passe 2

`EP3` Statut dans l'emploi (salarié, indépendant, patron, etc.)

`branche1` Branche d'activité économique (Agriculture / Industrie / Commerce / Autre service), construite depuis le code CIAP

`code_citp3` Code CITP-08 à 3 positions (groupe de base), dérivé du code 6 positions par `int(code/1000)`

`HH12` Région administrative

`HH6` Milieu de résidence (1 = Urbain, 2 = Rural)

Le repli progressif garantit qu'aucune valeur manquante ne subsiste faute de cellule suffisamment peuplée.

Gestion de la qualité

Entretiens supprimés

Motif	Nombre	Critère
Entretiens problématiques	6	Identifiés manuellement
Entretiens vides	131	`HH14 == .`
Entretiens en surnombre	1	Excédent selon région/ZD
Total	**138**	

Traçabilité des erreurs

Chaque problème identifié est exporté dans un fichier Excel nommé explicitement dans `document/` avant d'être corrigé (ex. : `E_WKT1_0.xlsx`, `SRH4_Manquants.xlsx`, `Erreur_L6_coh.xls`). Cela permet de justifier chaque décision de correction et de retracer les anomalies jusqu'à l'enquêteur responsable.

Variables construites

Variable	Description
`EN_EMP`	Statut d'emploi agrégé (1 = en emploi, 0 = hors emploi)
`branche1`	Branche CIAP agrégée, 4 modalités

`branche2`	Branche CIAP agrégée, 3 secteurs + non classés
`code_citp3_emp_principal`	Code CITP-08 emploi principal, 3 positions
`code_citp3_emp_secondaire`	Code CITP-08 emploi secondaire, 3 positions
`code_citp3_pluriactivite1-4`	Codes CITP-08 autres emplois, 3 positions
`NB_HEURE_TRAVAIL_TOTAL`	Heures totales travaillées toutes activités

Points d'attention pour la prochaine vague

1. **Interface avec la pondération** : le passage de `T4_2025_v` vers `ENE_SURVEY_WEIGHTS` est actuellement manuel (copie de fichiers). Une automatisation via un script de transfert réduirait le risque d'erreur.

2. **Bronze inviolable** : le fichier `Suppression_entretiens` écrit dans `datain/brute/`. Pour une architecture médaillon stricte, les fichiers bruts devraient être en lecture seule et la suppression effectuée à l'entrée de la couche Silver.

3. **Fichiers volumineux** : `01-traitrement_autres.do` (562 Ko) et `Codification_T4_2025.do` (542 Ko) contiennent des centaines de `replace` manuels. Une approche par table de correspondance Excel réduirait la maintenance.

4. `01-INDIV_S15_disponibilite.do` : fichier stub, à implémenter ou à retirer définitivement.

Document généré depuis l'inspection du code source – Avril 2026
Pipeline : `apurement.do` → 26 do-files → `Fusion.do`